

Projekt: Mini-AutoML dla Danych
Tabelarycznych

Mini-AutoML

Julia Dudzińska

Weronika Gozdera

Mikołaj Ozimek

29.01.2026



Opis projektu

- Implementacja uproszczonego systemu automatycznego uczenia maszynowego (MiniAutoML) do binarnej klasyfikacji na danych tabelarycznych.
- Wykorzystanie portfolio modeli stworzonego poprzez screening na podstawie wyników zewnętrznych (MementoML).
- System umożliwia 3 sposoby selekcji modeli:
 - Walidacja krzyżowa (CV)
 - Stabilność
 - Heurystyczna
- System umożliwia 3 typy ensemblingu:
 - Soft voting
 - Hard voting
 - Stacking

Selekcja Modeli: Podejście A

- Wstępne testy na 4 modelach i 10 zbiorach danych
- Problemy wydajnościowe i duplikujące się konfiguracje
- Porzucenie podejścia

Selekcja Modeli: Podejście B

- Portfolio modeli zbudowano na wynikach zewnętrznych benchmarków
- Użyto benchmarku **MementoML**:
 - zawiera testy dla siedmiu algorytmów uczenia maszynowego (catboost, gbm, xgboost, glmnet, kknn, randomForest oraz ranger)
 - obejmuje 39 zbiorów danych do klasyfikacji binarnej z OpenML100
 - w procesie tworzenia zbiory danych podzielono na 20 par treningowo-testowych, mierząc ACC, AUC oraz czas uczenia

Proces selekcji

- Preprocessing:
 - mapowanie funkcji i hiperparametrów z R do Python/scikit-learn
 - część modeli pominięto z powodu braku odpowiedników, problemów z instalacją, braków w zbiorze danych
- Selekcja:
 - ograniczenie do 10 modeli danego typu dla zachowania różnorodności (limity liczby modeli dla XGBoost i KNN zostały dostosowane na podstawie analizy wyników)
 - ranking modeli na podstawie agregacji wyników, obliczając średnią i odchylenie standardowe AUC i CV

Miara wyboru modeli

$$Score_{comp} = 0,7 \cdot AUC_{norm} + 0,3 \cdot (1 - CV_{norm})$$

$Score_{comp}$ – końcowy wynik punktowy modelu (wyższa wartość oznacza lepszy model).

AUC_{norm} – znormalizowana średnia wartość AUC, obliczana jako:

$$\frac{AUC_{mean} - AUC_{min}}{AUC_{max} - AUC_{min}}$$

CV_{norm} – znormalizowany współczynnik zmienności, obliczany jako:

$$\frac{CV - CV_{min}}{CV_{max} - CV_{min}}$$



AUC_{mean} – średnia arytmetyczna wyników AUC ze wszystkich prób.

CV – współczynnik zmienności ($CV = \frac{AUC_{std}}{AUC_{mean}}$), określający stabilność modelu.


Wyniki

Tabela 1: Rozkład modeli w finalnym portfolio

Typ modelu	Liczba	AUC _{mean}	CV _{mean}	Score _{comp}
XGBClassifier	15	0.9992	0.0003	0.9997
GradientBoostingClassifier	10	0.9075	0.1147	0.7811
LogisticRegression	10	0.8597	0.1556	0.6821
RandomForestClassifier	10	0.9175	0.1079	0.8006
KNeighborsClassifier	5	0.8828	0.1351	0.7305



Architektura systemu



Preprocessing danych

Zmienne numeryczne

- Imputacja: **mediana**
- Standaryzacja: **StandardScaler**

Zmienne katagoryczne

- Imputacja: **najczęściej występująca wartość**
- **One-Hot encoding**

Strategie selekcji modeli

Walidacja krzyżowa

- k-fold CV
- ranking według średniej wartości metryki (Balanced Accuracy)

Heurystyka

- Wstępny ranking modeli na podstawie liczby obserwacji, cech, zbalansowania klas
- k-fold CV dla top 10 kandydatów

Metryka stabilności

- k-fold CV
- Ranking według średniej wartości metryki pomniejszonej o iloczyn odchylenia standardowego i progu stabilności

Optymalizacja selekcji

Etap 1 - szybka ewaluacja

- Podzbiór danych (50%)
- Zachowanie proporcji klas (stratified)
- Ranking wszystkich modeli

Etap 2 - refinement

- Top N modeli (N - dwukrotność modeli oczekiwanych w ensemblingu)
- Ocena wybranych modeli na całym zbiorze treningowym
- Aktualizacja rankingu

Eksperymenty

Parametr	Badany zakres	Optymalna wartość
Strategia selekcji	CV, stabilność, heurystyka	Metryka stabilności
Liczba foldów CV	3-5	3
Liczba modeli do ensemble	1-5	2
Strategia ensemble	Soft Voting, Hard Voting, Stacking	Hard Voting
Próg stabilności	0.0 - 1.0	0.281

- 20 prób z Optuna
- Zbiór: diabetes (OpenML)
- Metryka: Balanced Accuracy
- Limit czasowy: ~10 min na próbę

**Dziękujemy za
uwagę**

